

# **Informe: Reconocimiento de Señales EEG en Tareas de Imaginación Motora (MI)**

**Elaborado por:** Santiago Galeano Castaño

Juan Diego Restrepo Hernández

**Presentado a:**  
Profesor Victor Alejandro

**Asignatura:**  
Sistemas en Tiempo Real

**UNIVERSIDAD NACIONAL DE COLOMBIA  
Sede Manizales**

**Diciembre 10 de 2025**

# Resumen Ejecutivo

Este informe resume los conceptos y desarrollos implementados respecto al reconocimiento de señales de electroencefalografía (EEG) en tareas de Imaginación Motora (Motor Imagery, MI). Se presenta una discusión detallada sobre las dificultades encontradas en la identificación de patrones espaciales, temporales y frecuenciales en estas señales, considerando la variabilidad entre sujetos y estímulos.

## 1. Introducción

La Imaginación Motora (MI) es una tarea cognitiva donde un sujeto imagina realizar un movimiento sin ejecutarlo físicamente. Esta actividad mental genera cambios característicos en los ritmos cerebrales, particularmente en las bandas Mu (8–13 Hz) y Beta (13–30 Hz) de la corteza sensoriomotora. El reconocimiento de estas señales mediante técnicas de procesamiento de señales y aprendizaje automático es fundamental para el desarrollo de Interfaces Cerebro-Computadora (BCI).

## 2. Conceptos Fundamentales Implementados

### 2.1. Protocolo de Adquisición y Montaje EEG

El código implementado utiliza el dataset **GI-GA-MI-ME**, que contiene señales EEG de múltiples sujetos realizando tareas de imaginación motora de mano izquierda y mano derecha. El montaje utilizado sigue el sistema internacional 10–20, con 64 canales distribuidos en las siguientes regiones:

- **Frontal:** Fp1, Fpz, Fp2, AF7, AF3, AFz, AF4, AF8, F7–F8, Fz
- **Central:** C1–C6, Cz, FC1–FC6, FCz, CP1–CP6, CPz
- **Parietal:** P1–P10, Pz, PO3–PO8, POz
- **Occipital:** O1, Oz, O2, Iz

- **Temporal:** T7, T8, TP7, TP8, FT7, FT8

La frecuencia de muestreo original se re-muestrea a **256 Hz** para estandarizar el procesamiento.

### 2.2. Preprocesamiento de Señales

#### 2.2.1. Filtrado Digital Butterworth

Se implementa un filtro Butterworth de orden 5 para aislar los ritmos cerebrales en diferentes bandas de frecuencia:

- **Delta:** 0.5 – 4 Hz
- **Theta:** 4 – 8 Hz
- **Alpha/Mu:** 8 – 13 Hz
- **Beta:** 13 – 32 Hz
- **Gamma:** 32 – 100 Hz

El filtrado se realiza utilizando `filtfilt` para evitar distorsiones de fase, aplicando el filtro en ambas direcciones (forward-backward).

#### 2.2.2. Representación Tiempo-Frecuencia

Se implementa la clase `TimeFrequencyRpr` que permite:

1. **Filtrado por bancos de frecuencia (f\_bank):** Aplica filtros pasabanda para aislar cada ritmo cerebral.
2. **Ventanas temporales deslizantes (vwt):** Segmenta la señal en ventanas de tiempo específicas para capturar la evolución temporal de los patrones MI.

La transformación genera un arreglo 5D con dimensiones:

- **Trials** (intentos)
- **Canales** (electrodos)
- **Muestras temporales** (por ventana)
- **Ventanas temporales**
- **Bandas de frecuencia**

## 2.3. Análisis Espectral

### 2.3.1. Transformada de Fourier (FFT)

Se utiliza la FFT para analizar el contenido frecuencial de las señales:

- **Espectro de magnitud:** Se calcula el módulo de la FFT y se representa en escala logarítmica (dB).
- **Frecuencias de interés:** Se identifican los picos espectrales correspondientes a los ritmos Mu y Beta, que son los más relevantes para MI.

### 2.3.2. Transformada de Fourier de Tiempo Corto (STFT)

La STFT permite visualizar la evolución temporal del contenido frecuencial mediante espectrogramas:

- **Ventana de análisis:** 0.5 segundos (128 muestras a 256 Hz)
- **Representación:** Mapa de calor tiempo-frecuencia que muestra la potencia espectral en cada instante

## 2.4. Extracción de Características Espaciales: Common Spatial Patterns (CSP)

El algoritmo **CSP** es fundamental para la clasificación de señales MI. Su implementación incluye:

1. **Principio:** Encuentra filtros espaciales que maximizan la varianza de una clase mientras minimizan la varianza de la otra.
2. **Transformación:** Proyecta las señales multicanales en un espacio de menor dimensionalidad (típicamente 2–4 componentes).
3. **Características:** Extrae la potencia promedio logarítmica de cada componente CSP.
4. **Aplicación multi-banda y multi-ventana:** Se aplica CSP de forma independiente para cada combinación de ritmo cerebral y ventana temporal.

## 2.5. Visualización

### 2.5.1. Topomapas

Los topomapas permiten visualizar la distribución espacial de la actividad cerebral:

- **Representación 2D:** Mapa de calor sobre el montaje 10–20
- **Aplicaciones:** Visualización de filtros CSP, potencia promedio por ritmo, distribución de artefactos

### 2.5.2. Gráficas Temporales

Visualización multi-canal de señales EEG en el dominio temporal, con desplazamiento vertical para facilitar la comparación entre canales.

## 3. Dificultades Encontradas: Inconsistencia en la Identificación de Patrones

### 3.1. Variabilidad Inter-Sujeto

Una de las principales dificultades identificadas en el código es la **alta variabilidad en el rendimiento de clasificación entre diferentes sujetos**. Esta inconsistencia se manifiesta en varios aspectos:

#### 3.1.1. Variabilidad en Patrones Espaciales

**Problema observado:** Los filtros CSP obtenidos para diferentes sujetos muestran distribuciones espaciales significativamente distintas, incluso cuando realizan la misma tarea (imaginación de mano izquierda vs. mano derecha).

##### Causas identificadas:

###### 1. Factores Anatómicos:

- El grosor del cráneo varía entre individuos (rango típico: 4–7 mm), lo que altera la atenuación y distorsión espacial de los campos eléctricos corticales.

- La orientación de las columnas corticales y la geometría del cerebro influyen en cómo se proyectan los potenciales sobre los electrodos.
- Diferencias en el volumen de conducción (conductividad de tejidos) afectan la propagación de señales.

## 2. Variabilidad en la Localización Funcional:

- La corteza motora primaria (M1) no está exactamente en la misma posición anatómica en todos los sujetos.
- La representación somatotópica del homúnculo motor varía en tamaño y localización.

**Evidencia en el código:** Al comparar sujetos (por ejemplo, sujeto 5 vs. sujeto 14), los topomapas de los filtros CSP muestran patrones espaciales diferentes, lo que requiere entrenar modelos específicos por sujeto.

## 3.1.2. Variabilidad en Patrones Temporales

**Problema observado:** La ventana temporal óptima para detectar la desincronización relacionada con eventos (ERD – Event-Related Desynchronization) varía entre sujetos.

**Causas identificadas:**

### 1. Latencia de la Respuesta:

- El tiempo entre el estímulo y el inicio de la ERD varía (típicamente 0.5–2 segundos).
- Algunos sujetos muestran una respuesta más rápida, mientras que otros requieren más tiempo para “activar” la imaginación motora.

### 2. Duración de la ERD:

- La duración de la desincronización Mu/Beta varía significativamente.
- Algunos sujetos mantienen la ERD durante todo el período de imaginación (0–7 segundos), mientras que otros muestran patrones intermitentes.

**Evidencia en el código:** El código implementa múltiples ventanas temporales ( $vwt = np.array([[0.25, 1.75], [1.5, 3], [2.75, 4.25], [4, 5.5], [5.25, 6.75]])$ ) para capturar diferentes fases de la respuesta, pero la ventana óptima varía entre sujetos.

## 3.1.3. Variabilidad en Patrones Frecuenciales

**Problema observado:** Las bandas de frecuencia que contienen la mayor información discriminativa varían entre sujetos.

**Causas identificadas:**

### 1. Ritmo Mu Individual:

- La frecuencia central del ritmo Mu varía entre 8–13 Hz, con picos individuales que pueden estar en 9 Hz, 10 Hz, 11 Hz, etc.
- Algunos sujetos muestran actividad más prominente en la banda Beta (13–30 Hz) que en Mu.

### 2. Armónicos y Sub-armónicos:

- Algunos sujetos muestran actividad en frecuencias específicas (por ejemplo, 20 Hz, 24 Hz) que no están presentes en otros.

**Evidencia en el código:** El código filtra en bandas amplias (8–13 Hz para Mu, 13–32 Hz para Beta), pero no adapta las bandas a las características individuales de cada sujeto.

## 3.2. Variabilidad Entre Estímulos (Intra-Sujeto)

Además de la variabilidad entre sujetos, se observa inconsistencia en la identificación de patrones **dentro del mismo sujeto** entre diferentes trials (intentos):

### 3.2.1. Inconsistencia Temporal Entre Trials

**Problema observado:** No todos los trials del mismo sujeto muestran el mismo patrón temporal de ERD.

**Causas identificadas:**

### 1. Fatiga Mental:

- A medida que avanza la sesión, la calidad de la imaginación motora puede degradarse.
- Los trials iniciales pueden mostrar patrones más claros que los finales.

### 2. Nivel de Concentración:

- La capacidad del sujeto para mantener la concentración varía entre trials.
- Distracciones externas o internas afectan la calidad de la señal.

### 3. Estrategias Cognitivas Variables:

- Un sujeto puede cambiar inconscientemente su estrategia de imaginación entre trials (por ejemplo, de kinestésica a visual).

**Evidencia en el código:** Los scatter plots de características CSP muestran solapamiento entre clases, indicando que no todos los trials son igualmente discriminables.

## 3.2.2. Variabilidad en la Intensidad de la Señal

**Problema observado:** La amplitud de la ERD varía significativamente entre trials del mismo sujeto.

### Causas identificadas:

#### 1. Intensidad de la Imaginación:

- Algunos trials representan una imaginación más “viva” y detallada que otros.
- La variabilidad en la intensidad mental se refleja en la amplitud de la desincronización.

#### 2. Artefactos Fisiológicos:

- La presencia de artefactos (parpadeos, movimientos musculares) varía entre trials.
- Estos artefactos pueden enmascarar o distorsionar la señal de interés.

## 3.3. Influencia de Artefactos Fisiológicos

Una solución propuesta identifica que los artefactos fisiológicos son una fuente crítica de variabilidad y dificultad en la identificación de patrones:

### 3.3.1. Artefactos Oculares (EOG – Electro-oculograma)

**Problema:** Los movimientos oculares y parpadeos generan potenciales de cientos de microvoltios, superando ampliamente la señal cerebral (típicamente 10–50  $\mu$ V).

#### Impacto:

- Los canales frontales (Fp1, Fp2, Fpz) son especialmente susceptibles.
- Estos artefactos distorsionan los filtros CSP, ya que el algoritmo utiliza la covarianza de todos los canales.
- El clasificador puede confundir la señal de parpadeo con actividad relacionada con MI.

**Evidencia:** En el análisis comparativo entre sujetos, se observa que sujetos con mayor frecuencia de parpadeos (por ejemplo, Sujeto 1) muestran menor rendimiento de clasificación (Accuracy  $\approx$  0.60) comparado con sujetos con menos artefactos (Sujeto 14, Accuracy  $>$  0.80).

### 3.3.2. Artefactos Musculares (EMG – Electromiograma)

**Problema:** La tensión muscular, especialmente en la mandíbula y cuello, genera actividad de alta frecuencia (20–200 Hz) que se filtra hacia las bandas Beta y Gamma.

#### Impacto:

- Los canales temporales (T7, T8) son particularmente afectados.
- La actividad EMG puede ser confundida con actividad Beta relacionada con MI.
- Aumenta la varianza de la señal, reduciendo la separabilidad de clases.

### **3.3.3. Artefactos Cardíacos (ECG – Electrocardiograma)**

**Problema:** Aunque menos común, los artefactos del pulso cardíaco pueden aparecer en canales cercanos al cuello.

**Impacto:** Genera patrones rítmicos que pueden interferir con la detección de ritmos cerebrales.

## **3.4. Factores Cognitivos y Psicológicos**

### **3.4.1. Estrategias Cognitivas Diferentes**

**Problema:** Los sujetos utilizan diferentes estrategias mentales para realizar la imaginación motora:

1. **Imaginación Kinestésica:** El sujeto “siente” el movimiento, activando principalmente la corteza sensoriomotora (ritmos Mu).
2. **Imaginación Visual:** El sujeto “ve” su mano moverse, activando áreas occipitales y temporales, confundiendo al clasificador.

**Impacto:** Los patrones espaciales y frecuenciales difieren significativamente entre estas estrategias, requiriendo que el algoritmo sea robusto a estas variaciones.

### **3.4.2. “BCI Illiteracy” (Analfabetismo BCI)**

**Problema:** Algunos sujetos (aproximadamente 15–30 % de la población) tienen dificultades inherentes para modular sus ritmos sensoriomotores (SMR).

#### **Causas propuestas:**

- Factores genéticos relacionados con la concentración de neurotransmisores (dopamina).
- Estructura de las conexiones de materia blanca.
- Experiencia previa limitada con tareas motoras finas.

**Impacto:** Estos sujetos muestran ERD muy débil o inconsistente, resultando en rendimientos de clasificación cercanos al azar (50 %).

### **3.4.3. Experiencia y Entrenamiento**

**Problema:** La experiencia previa con BCI o actividades que requieren control motor fino (músicos, deportistas) influye en la calidad de las señales.

#### **Impacto:**

- Sujetos entrenados muestran ERD más robusta y consistente.
- La plasticidad cerebral facilita la modulación de ritmos con el entrenamiento.

## **3.5. Limitaciones del Algoritmo CSP**

El código implementa CSP, que aunque es efectivo, tiene limitaciones inherentes que contribuyen a las inconsistencias:

### **3.5.1. Sensibilidad a Artefactos**

**Problema:** CSP es altamente sensible a artefactos, ya que busca maximizar la varianza entre clases. Si los artefactos están correlacionados con las etiquetas (por ejemplo, un sujeto parpadea más durante una clase que otra), CSP puede aprender a detectar artefactos en lugar de actividad MI.

### **3.5.2. Asunción de Estacionariedad**

**Problema:** CSP asume que las señales son estacionarias dentro de cada trial, pero la actividad MI es inherentemente no estacionaria (la ERD evoluciona en el tiempo).

**Impacto:** Requiere segmentación en ventanas temporales, pero la selección de ventanas óptimas es subjetiva y varía entre sujetos.

### **3.5.3. Dependencia del Tamaño de Muestra**

**Problema:** CSP requiere un número suficiente de trials para estimar correctamente las matrices de covarianza. Con pocos trials, los filtros pueden sobreajustarse a ruido.

- ## 4. Soluciones Propuestas y Mejoras
- ### 4.1. Preprocesamiento Avanzado de Artefactos
- Basado en el análisis del notebook de artefactos fisiológicos, se proponen las siguientes mejoras:
- 1. ICA (Análisis de Componentes Independientes):**
    - Separar componentes independientes de la señal.
    - Identificar y eliminar componentes relacionados con EOG, EMG y ECG.
    - Preservar componentes relacionados con actividad cerebral.
  - 2. Filtrado Adaptativo:**
    - Detección automática de artefactos mediante umbrales estadísticos.
    - Rechazo de trials con artefactos excesivos.
  - 3. Regresión de Artefactos:**
    - Utilizar canales de referencia (EOG, EMG) para restar artefactos de los canales EEG.
- ### 4.2. Adaptación Individual (Transfer Learning)
- Para abordar la variabilidad inter-sujeto:
- 1. Calibración por Sujeto:**
    - Entrenar modelos específicos para cada sujeto con datos de calibración.
    - Ajustar bandas de frecuencia y ventanas temporales individualmente.
  - 2. Transfer Learning:**
    - Pre-entrenar modelos con datos de múltiples sujetos.
    - Fine-tuning con pocos datos del sujeto objetivo.
- ### 4.3. Métodos Robustos a No-Estacionariedad
- 1. CSP Adaptativo:**
    - Actualizar filtros CSP en tiempo real durante la sesión.
  - 2. Métodos de Aprendizaje Profundo:**
    - Redes neuronales convolucionales (CNN) para capturar patrones espacio-temporales.
    - Redes de atención para identificar ventanas temporales relevantes automáticamente.
- ### 4.4. Selección Automática de Características
- 1. Selección de Canales:**
    - Identificar automáticamente los canales más informativos para cada sujeto.
    - Reducir la dimensionalidad y el impacto de canales ruidosos.
  - 2. Selección de Bandas de Frecuencia:**
    - Análisis espectral individual para identificar bandas óptimas.
    - Filtros adaptativos basados en la densidad espectral de potencia (PSD).

## 5. Conclusiones

El reconocimiento de señales EEG en tareas de MI presenta desafíos significativos relacionados con la **alta variabilidad inter e intra-sujeto** en los patrones espaciales, temporales y frecuenciales. Las principales dificultades identificadas incluyen:

- 1. Variabilidad Anatómica y Funcional:** Diferencias en la estructura cerebral y localización funcional entre sujetos.
- 2. Artefactos Fisiológicos:** EOG, EMG y ECG que enmascaran o distorsionan la señal de interés.

3. **Factores Cognitivos:** Estrategias mentales diferentes, “BCI Illiteracy”, y variabilidad en la intensidad de la imaginación.
4. **Limitaciones de los Algoritmos:** CSP y otros métodos tradicionales son sensibles a estas variabilidades.

Las soluciones propuestas, incluyendo preprocesamiento avanzado de artefactos (ICA), adaptación individual, y métodos de aprendizaje profundo, ofrecen caminos prometedores para mejorar la robustez y generalización de los sistemas BCI basados en MI.

Sin embargo, es fundamental reconocer que este proyecto representa uno de los desafíos más complejos en el campo del procesamiento de señales biomédicas y las interfaces cerebro-computadora. La dificultad inherente radica en la naturaleza fundamentalmente no estacionaria y altamente variable de las señales EEG, que se ve exacerbada por múltiples factores que interactúan de manera no lineal y difícil de modelar. La señal de interés, que típicamente oscila entre 10 y 50 microvoltios, se encuentra constantemente sumergida en un mar de ruido que puede ser órdenes de magnitud más fuerte, como es el caso de los artefactos oculares que alcanzan cientos de microvoltios. Esta relación señal-ruido extremadamente desfavorable hace que la tarea de extraer información útil sea comparable a intentar escuchar una conversación suurrada en medio de una tormenta.

La variabilidad inter-sujeto no es simplemente una cuestión de parámetros ajustables, sino que refleja diferencias fundamentales en la neuroanatomía, neurofisiología y neuroquímica de cada individuo. Cada cerebro es único en su estructura, con variaciones en el grosor del cráneo que pueden alterar la atenuación de señales hasta en un 40 %, diferencias en la orientación de las columnas corticales que modifican la proyección espacial de los campos eléctricos, y variaciones en la localización funcional de áreas motoras que pueden desplazarse varios centímetros entre individuos. Estas diferencias anatómicas se traducen en que un modelo entrenado en un sujeto prácticamente no puede generalizar a otro sin recalibración extensiva, lo que limita severamente la aplicabilidad práctica de sistemas BCI universales.

Además, la variabilidad intra-sujeto introduce una capa adicional de complejidad que hace que incluso para un mismo individuo, la consistencia de las señales sea un desafío constante. La calidad de la imaginación motora fluctúa significativamente entre trials debido a factores como la fatiga mental, el nivel de concentración, y cambios inconscientes en las estrategias cognitivas empleadas. Un sujeto puede comenzar una sesión utilizando una estrategia kinestésica que activa predominantemente la corteza sensoriomotora, pero sin darse cuenta puede cambiar a una estrategia visual que activa áreas occipitales, generando patrones completamente diferentes que confunden al clasificador. Esta inconsistencia temporal hace que el problema sea inherentemente no estacionario, violando uno de los supuestos fundamentales de muchos algoritmos de procesamiento de señales.

El fenómeno conocido como “BCI Illiteracy” añade otra dimensión crítica a la dificultad del problema. Aproximadamente entre el 15 % y 30 % de la población tiene dificultades inherentes para modular sus ritmos sensoriomotores, resultando en señales tan débiles o inconsistentes que son prácticamente indistinguibles del ruido de fondo. Esta limitación no es simplemente una cuestión de entrenamiento o motivación, sino que parece tener bases genéticas y neurobiológicas profundas relacionadas con la estructura de las conexiones de materia blanca y la concentración de neurotransmisores como la dopamina. Para estos sujetos, incluso con las técnicas más avanzadas de procesamiento de señales, lograr una clasificación confiable se acerca a lo imposible, limitando la aplicabilidad universal de los sistemas BCI basados en MI.

Los artefactos fisiológicos representan otro obstáculo formidable que no puede ser simplemente filtrado o eliminado. Los artefactos oculares, musculares y cardíacos no solo enmascaran la señal de interés, sino que pueden estar correlacionados con las etiquetas de clase de manera que confunden directamente a los algoritmos de clasificación. Por ejemplo, si un sujeto tiende a parpadear más durante la imaginación de mano izquierda que durante la de mano derecha, el algoritmo CSP puede aprender a detectar parpadeos en lugar de actividad motora, generando falsos positivos que comprometen la

confiabilidad del sistema. La eliminación de estos artefactos mediante técnicas como ICA requiere experiencia significativa y puede introducir artefactos propios si no se realiza correctamente.

Las limitaciones de los algoritmos actuales, particularmente CSP, se vuelven evidentes cuando se enfrentan a estas múltiples fuentes de variabilidad. CSP asume estacionariedad, independencia entre canales en ciertos aspectos, y requiere un número suficiente de trials para estimar matrices de covarianza confiables. Sin embargo, en la práctica real, estas asunciones raramente se cumplen. La actividad MI es inherentemente no estacionaria, los canales están altamente correlacionados debido a la naturaleza de la propagación de campos eléctricos en el volumen conductor de la cabeza, y obtener suficientes trials de alta calidad es costoso en términos de tiempo y puede llevar a fatiga del sujeto que degrada la calidad de los datos.

La combinación de todos estos factores hace que el reconocimiento de señales EEG en tareas de MI sea un problema que se encuentra en la frontera de lo que es técnicamente factible con las tecnologías actuales. Aunque las soluciones propuestas, incluyendo preprocessamiento avanzado de artefactos mediante ICA, adaptación individual mediante transfer learning, y métodos de aprendizaje profundo, ofrecen mejoras incrementales, ninguna de ellas resuelve completamente el problema fundamental de la variabilidad inherente. Cada solución introduce sus propias complejidades: ICA requiere selección manual de componentes, el transfer learning necesita datos de calibración extensivos, y los métodos de aprendizaje profundo requieren grandes cantidades de datos etiquetados que son costosos de obtener.

En última instancia, el reconocimiento confiable de señales EEG en tareas de MI para aplicaciones del mundo real sigue siendo un objetivo elusivo que requiere no solo avances técnicos en algoritmos y procesamiento de señales, sino también una comprensión más profunda de la neurobiología subyacente y el desarrollo de protocolos experimentales que minimicen las fuentes de variabilidad. La dificultad del problema no debe subestimarse, ya que representa uno de los desafíos más complejos en la intersección entre neurociencia, procesamiento de señales e inteligencia

artificial.

## Recursos y Código Fuente

Este apartado contiene los enlaces a los notebooks de Kaggle donde se implementaron los ejercicios clave del análisis de señales EEG.

### Implementación del Pipeline BCI (2.1 y 2.3)

El código fuente que incluye el pipeline completo de preprocessamiento, extracción de características (CSP) y clasificación (LDA) se encuentra en el siguiente notebook:

- Notebook      Kaggle: <https://www.kaggle.com/code/jhonyisiv/proyecto-final-giga-science-eegmi-gcpds>

### Análisis de Artefactos Fisiológicos (2.4)

El análisis específico sobre la influencia de artefactos fisiológicos en la señal EEG se implementó en el siguiente notebook:

- Notebook      Kaggle: <https://www.kaggle.com/code/sgaleanoca/influencia-artefactos-fisiol-gicos-punto-2-4>

## 6. Referencias y Notas Técnicas

### 6.1. Dataset Utilizado

- **GIGA\_MI\_ME**: Dataset de señales EEG de imaginación motora con múltiples sujetos y sesiones.

### 6.2. Herramientas y Librerías

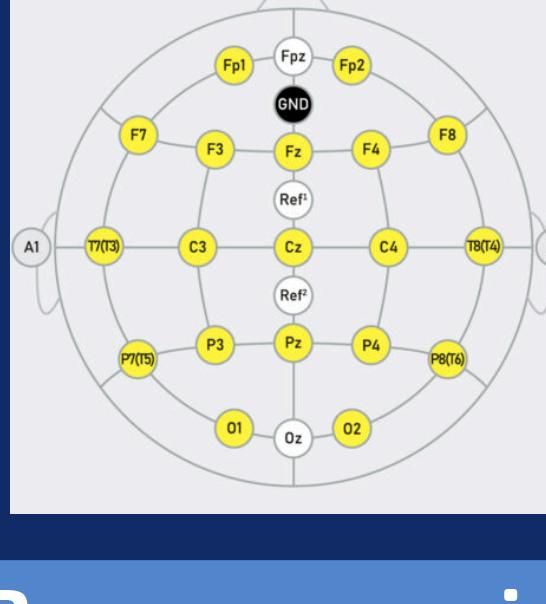
- **MNE-Python**: Procesamiento de señales neurofisiológicas
- **scikit-learn**: Implementación de CSP y clasificadores

- **NumPy/SciPy:** Procesamiento numérico y filtrado de señales
- **Matplotlib:** Visualización de datos

### 6.3. Parámetros Clave del Código

- **Frecuencia de muestreo:** 256 Hz
- **Bandas de frecuencia:** Delta (0.5–4 Hz), Theta (4–8 Hz), Alpha/Mu (8–13 Hz), Beta (13–32 Hz), Gamma (32–100 Hz)
- **Componentes CSP:** 2–4 componentes típicamente
- **Ventanas temporales:** Múltiples ventanas de 1–2 segundos dentro del trial de 7 segundos

# Pipeline BCI para Imaginación Motor: De EEG a la Clasificación Óptima con Filtros CSP

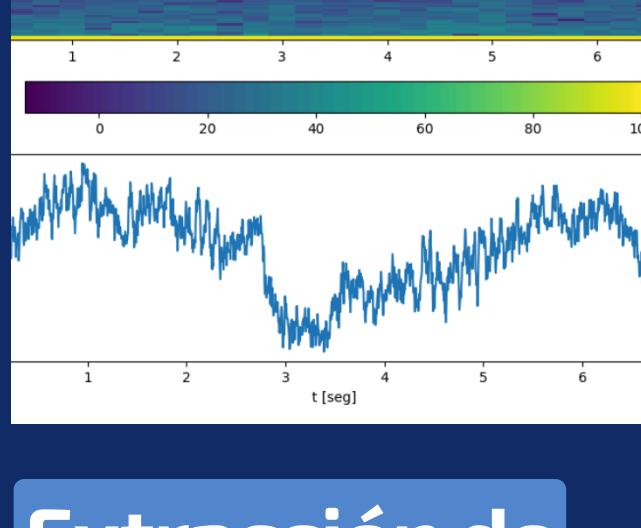


## Entrada y Fundamento

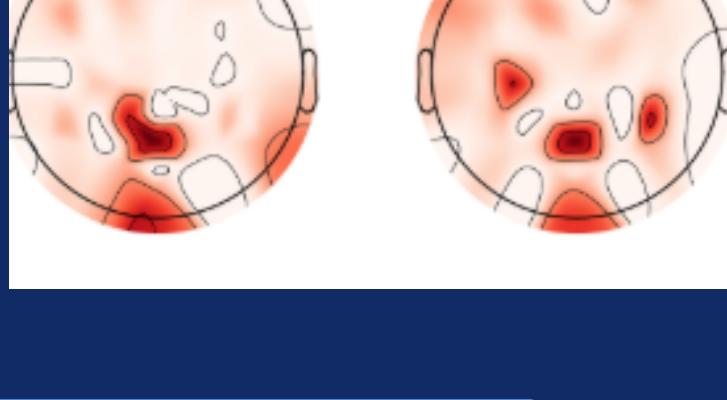
- Señal EEG: Captura de la actividad eléctrica cerebral a través de 64 canales.
- Tarea: Clasificación binaria (Mano Izquierda vs. Mano Derecha) basada en la modulación del ritmo sensoriomotor.
- Reto: La señal es ruidosa y el patrón cerebral varía entre sujetos.

## Preprocesamiento Frecuencial

- Filtros: Uso de Filtros IIR Butterworth (banda de 5 bandas) para descomponer la señal en sus ritmos (Delta, Theta, Alpha, Beta, Gamma).
- Análisis Clave: El foco está en la banda Alpha (8-13 Hz) y Beta (18-26 Hz), donde se observa la Desincronización Relacionada con Eventos (ERD), que es una caída de potencia durante la imaginación motora.
- Validación: Se usa el STFT para validar visualmente la aparición del ERD en el espectrograma.



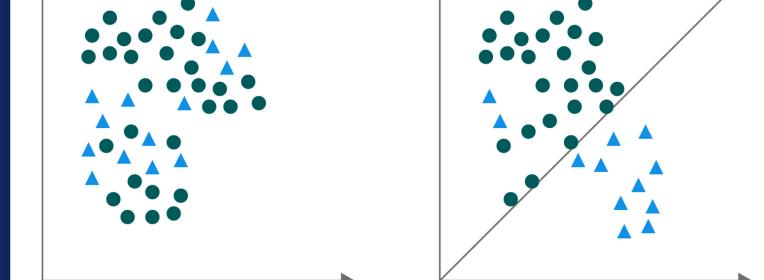
## Extracción de Características Adaptativa



- Problema Resuelto: Se aborda la inconsistencia espacial del patrón motor (no siempre perfecto en C3/C4).
- Función CSP: Es un filtro supervisado que busca la combinación lineal de todos los canales que:
  - Maximiza la varianza de una clase (ej., Mano Izquierda, amplificando C4).
  - Minimiza la varianza de la otra clase (ej., Mano Derecha, suprimiendo C3).
- Validación Espacial: Las topografías CSP confirman que los filtros amplifican las regiones motoras esperadas (C3 para Mano Derecha, C4 para Mano Izquierda).

## Clasificación y Resultado Final

- Modelo: Clasificador LDA (Análisis Discriminante Lineal).
- Características: Alimentado por las características CSP (varianza logarítmica).
- Evaluación: Uso de Validación Cruzada Estratificada para garantizar la robustez del resultado.
- Rendimiento Final: 60.78% de precisión.
- Conclusión: Este resultado es significativamente efectivo (superior al azar del 50%) y valida la implementación técnica.

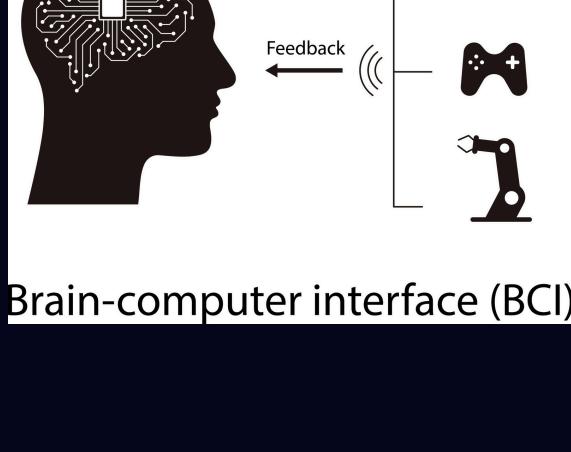




El análisis de señales EEG es complejo debido a su alta susceptibilidad al ruido y a la gran variabilidad entre individuos; esta falta de uniformidad, causada por factores biológicos y cognitivos, complica la extracción de patrones claros y representa un obstáculo mayor para desarrollar sistemas universales que funcionen para cualquier usuario.

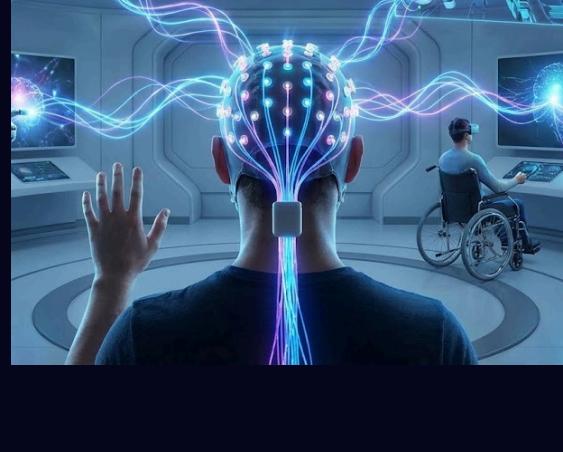
## Encefalografía

La imaginación motora consiste en simular mentalmente un movimiento sin ejecutarlo físicamente, proceso que activa la corteza motora de forma análoga a la acción real y genera cambios detectables en las bandas de frecuencia Alpha (ritmo Mu) y Beta.



## Interfaces Cerebro-Computador (BCI)

Un sistema BCI crea un canal de comunicación directo entre el cerebro y un dispositivo externo, evitando los nervios periféricos y los músculos.



## Paradigma de la Imaginación Motora

La imaginación motora consiste en simular mentalmente un movimiento sin ejecutarlo físicamente, proceso que activa la corteza motora de forma análoga a la acción real y genera cambios detectables en las bandas de frecuencia Alpha (ritmo Mu) y Beta.

## Relación del MI con EEG y BCI

La Imagería Motora (MI) permite generar comandos cerebrales voluntarios simplemente pensando en moverse. El EEG actúa como el sensor que captura esta actividad eléctrica en la superficie del cráneo. Finalmente, el sistema BCI analiza estos patrones oscilatorios para traducir la intención humana en control de máquinas en tiempo real.

